

Auditoria estatística das contagens — Eleições 2022

Autor: Flávio Mamede Pereira Gomes

Data: 26 de setembro de 2026

Escopo: 1º e 2º turnos da eleição presidencial; boletins de urna do TSE; modelo de urna por seção (logs TSE / projeto John Robson); coordenadas de locais (Hidalgo v0.16); polígonos municipais (geobr).

Referências metodológicas: Cochran–Mantel–Haenszel; regressão ecológica (Goodman); Forsberg, *Understanding Elections through Statistics* (CRC, 2021), caps. 6–7.

Sumário executivo

Este relatório separa com rigor **indício e prova**. Indício é distorção real e estatisticamente significativa relacionada ao fato; basta, *conforme queríamos demonstrar*, para afirmar que há o que investigar. Prova exige ainda destino discriminante (relação causal com a urna que sobrevive a controles) e, no limite, registro independente do software.

Há diferença agregada entre a proporção Lula/Bolsonaro nas urnas anteriores a 2020 e nas UE2020 — **indício real**. Nos **1.353 locais** com os dois modelos lado a lado, descontada a composição legislativa, o contraste cai a **+0,01 pp** ($t = 0,13$). Esse nível de comparação atribui o indício agregado, na maior parte, à **alocação** dos equipamentos — sem invalidar outros indícios obtidos por vias distintas (Forsberg).


Pelos critérios do Cap. 6 de Forsberg, há **associação estatística** entre taxa de brancos+nulos e apoio a Lula (coef. logit $\approx +0,35$; $z \gg 2$). Isso é *unfairness* possível e, na terminologia deste projeto, **é indício** do que pode ser fraude — não prova isolada. O sinal não é uniforme no país: é mais forte (z elevado, coeficiente positivo) em UFs como SP, RS, MS, PB, ES, PE; em outras (CE, PA, PR, PI...) o coeficiente inverte de sinal. Os resíduos desse modelo ainda têm Moran **I $\approx 0,57$** : os desvios se agrupam no espaço (clusters HH significativos sobretudo em SP, BA, PE, PB).

Pelo Cap. 7, modelos espaciais baixam o coeficiente da fração de urnas antigas sobre a proporção de Lula de cerca de **+3,3 pp** (MQO) para **+1,4 pp** (erro espacial). Neutro, na escala do mesmo prédio, seria $\approx +0,01$ pp. **+1,4 pp não é neutro**: permanece **indício** associado à urna/lugar após controle espacial global. Ainda não é prova nem indício discriminante a favor da fraude (falta a calibração F4a no domínio onde a referência é conhecida); mas tampouco se pode dizer que o Cap. 7 “zerou” o efeito.

Conclusão para o leitor: há indícios com significância estatística (Caps. 6 e 7, além do contraste agregado). Não há prova de fraude por modelo de urna. O azul do mapa de Lula continua sendo geografia do voto, não o teste de Forsberg.

1. Conceitos e fundamentos

1.1 Indício, indício discriminante e prova



Protocolo

Figura 1 — Do indício ao destino (protocolo de auditoria).


Neste trabalho os termos seguem o sentido do direito brasileiro (CPP art. 239; CPPM arts. 382–383), e não o inglês *evidence*:

Nível	Critério
Indício	Distorção real e significativa relacionada ao fato
Indício discriminante	A relação causal com a urna sobrevive ao teste de mesmo local, aos controles negativos e à confirmação
Indício forte	Discriminante e convergente com indícios independentes (carga, flashcard, fatores humanos)
Prova	Forte e coincidente com registro independente do software
Exclusão de mecanismo	Teste com poder $\geq 90\%$ para fraude capaz de alterar o resultado, sem sinal

Cada indício recebe um de três destinos: **atribuído à alocação**, **atribuído à fraude** ou **indeterminado**. Encontrar indício *do que pode ser fraude* (associação estatística compatível com unfairness ou com efeito residual de urna) **já satisfaz** o objetivo intermediário da auditoria — *conforme queríamos demonstrar* — sem confundir isso com prova.

1.2 Confundimento espacial (P0)

O modelo de urna não foi sorteado. As UE2020 concentram-se em capitais e municípios maiores; as antigas, no interior. Dentro das zonas, a alocação ainda corre por prédio de votação. Qualquer contraste bruto entre marcas mistura **lugar** e **equipamento**.



Mapas Lula e urnas

Figura 2 — Geografia do voto (Lula, 2º turno) e da alocação (fração de urnas antigas), por município. Os dois mapas não são independentes.

O azul do mapa é indício de fraude?

Não. No painel da esquerda, **azul escuro = município em que Lula teve maior fração dos votos válidos** entre Lula e Bolsonaro (escala ~20% a ~80%). Vermelho escuro = o contrário. A “quantidade visual de azul” é, portanto, a **geografia do eleitorado** no 2º turno — Norte e Nordeste votaram mais em Lula; Sul, parte do Sudeste e Centro-Oeste, mais em Bolsonaro. Isso é o resultado oficial agregado no mapa; não é um teste de integridade da urna.

O que o par de mapas *mostra* de útil à auditoria é outra coisa: o painel da direita (marrom = quase só urnas antigas) cobre grande parte do território, inclusive onde o azul é dominante. Quem olha os dois juntos e conclui “azul = fraude nas antigas” comete o erro clássico de **confundimento**: lugar, perfil social e marca de urna caminham juntos. O Cap. 7 de Forsberg existe precisamente para obrigar o analista a modelar essa dependência espacial em vez de ler cor como prova.

1.3 Taxas de transferência e scores

A ideia por trás dos scores do VotoReal é uma **tabela de transferência**: dado o voto em deputado (ou partido), que fração “iria” a Bolsonaro ou a Lula. A calibragem objetiva estima essas taxas por regressão ecológica restrita **somente nas seções UE2020** de cada UF e aplica a mesma tabela às seções com urna antiga. O erro relativo resultante mede desajuste de domínio — não, por si, fraude.

1.4 Invalidação diferencial (Forsberg, cap. 6)

Sob a hipótese de eleição livre e justa, a taxa de brancos e nulos deve ser **independente** do apoio ao candidato. Relação significativa é *unfairness* possível e, neste relatório, **conta como indício** (do que pode ser fraude) — não como prova *per se*. Números, mapa por UF e clusters: **seção 6**.

1.5 Autocorrelação espacial (Forsberg, cap. 7)


Vizinhos votam parecido; a alocação de urnas também se agrupa no mapa. O Cap. 7 não “apaga” indícios: ele exige que o efeito estimado sob controle espacial seja lido contra uma referência neutra (no mesmo prédio, $\approx +0,01$ pp). Detalhe na seção 6.

2. Dados e unidade de análise

Fonte	Uso
Boletins de urna TSE (bweb_*) → base larga secoes_2022_t{1,2}	472.028 seções; totais Lula/Bolsonaro batem com a referência oficial
Modelo de urna por seção (logs TSE / John Robson)	UE2020 (= Positivo) vs anteriores (= Diebold, em regra)
Hidalgo geocode_br_polling_stations v0.16	Coordenadas de ~92,3 mil locais; 99,1% dentro do município IBGE
geobr municípios 2022	Polígonos; validação ponto-no-polígono

Unidades usadas neste relatório: **seção, local de votação** (prédio), **município, UF**.

3. Hierarquia de contrastes: o efeito encolhe




Hierarquia

Figura 5 — Efeito associado à urna antiga (pontos percentuais a favor de Lula) em sucessivos níveis de controle.

Nível	Efeito (pp)	Leitura
Dentro da zona (Brasil, sem covariáveis)	+1,27 (t = 5,4)	Índice I2
Mesmo local + composição legislativa	+0,01 (t = 0,13)	Comparação no prédio
MQO espacial (locais, k=8)	+3,29	Ainda mistura geografia
Erro espacial ($\lambda \approx 0,85$)	+1,39	Reduz, não chega a 0,01

A diferença entre +1,39 (erro espacial global) e +0,01 (mesmo local) mede o viés que resta quando se força um coeficiente único no país — limitação que Forsberg aponta e que GWR/SLEM tratam.

4. Proposições: o que ficou estabelecido ou refutado



Rede

Figura 6 — Indicadores de verdade (0 = refutada; 1 = estabelecida).

4.1 Relatório CMH / modelo de urna

Nº	Proposição	Indicador	Fundamento
P0	Modelo de urna entrelaçado com localização e perfil	1,00	Premissa confirmada em todos os níveis
P1	Há correlação agregada modelo × voto	1,00	R bruto $\approx 1,15-1,17$
P2	Há diferença intrazonal nacional	1,00	+1,27 pp, t = 5,4
P2a	Essa diferença é homogênea no país	0,03	Concentrada em SP
P3	p-valores CMH por voto são válidos como reportados	0,00	Dispersão; a rejeição de H0 sobrevive com a seção
P4	Dentro das zonas, alocação independe do perfil	0,00	Negação de P0
P4'	No mesmo local, seções antigas e UE2020 são comparáveis	0,85	Controles negativos equilibrados
P5	O modelo de urna causou a diferença	0,03	Nulo no prédio, com poder para 1%
P6a/b	Fraude detectable ($\geq 1\%$) nas antigas	0,02–0,03	Nulo no prédio (Brasil e SP)
P6c	Intrazonal aponta efeito das antigas no Nordeste	0,02	Sinal contrário / nulo
P7	Evidência equivalente a tabagismo–câncer	0,00	Analogia inválida
P10	A diferença inverte o resultado	0,00	Magnitude intramunicipal $\ll$ margem

4.2 Scores VotoReal

Nº	Proposição	Indicador	Fundamento
R1	Tabela subjetiva JR = taxas reais	0,05	Afasta-se em PP, Republicanos, PSOL, NOVO...
R2	Regra UE2020 por UF erra nas antigas da mesma UF	1,00	Erro relativo estável 1º ↔ 2º turno
R3	Hold-out 70/30 valida extrapolação às antigas	0,00	Valida só dentro das Positivo
R4	Erro de R2 = efeito de marca	0,03	T1 grande com mesma marca; T2 ≈ 0

4.3 Cauda de votação mínima


Nº	Proposição	Indicador
U1	Mínimos de Bolsonaro nas antigas por efeito do modelo	0,02
U2	Nas 27 seções do AM sem Bolsonaro, o voto destoa dos demais cargos	0,00

4.4 Mecanismos M1–M5

Mecanismo	Situação
M1 Manipulação após a urna (totalização)	Excluída (soma dos BUs = resultado oficial)
M2 Transferência específica das urnas antigas ($\geq 1\%$ nos testados)	Excluída com poder demonstrado
M3 Manipulação concentrada na escala da margem	Excluída
M4 Dispersa sem reconhecer teste de integridade	Excluída (prob. $\geq 99,6\%$ no desenho do pacote)
M5 Dispersa, comum a todos os modelos, reconhecendo o teste	Indeterminada
D-ext Só em municípios sem comparação interna	Em aberto (análise geográfica)

5. Calibragem dos scores e controles T1/T2/T3

5.1 Contraste Positivo → Diebold por UF




Contraste UF

Figura 7 — Δ de erro relativo (Diebold – Positivo) após calibrar nas UE2020. PB, AL, PE, AM, CE... ultrapassam 20–30% em Bolsonaro. SP, MG, DF ficam perto de zero.

Atenção: nos estados de maior Δ , capital $\approx$ UE2020 e interior $\approx$ antigas. O Δ **mistura** capital/interior com eventual efeito de marca. Por isso os controles abaixo.


5.2 Scores subjetivos × calibrados



Scores

Figura 8 — No eixo x, o score do site; no y, a taxa média calibrada (Dep. Federal, 1º turno). A diagonal é a concordância perfeita. PL e PT apontam o mesmo lado; PP, Republicanos, PSOL e NOVO afastam-se bastante.

5.3 Controles: T1 grande, T2 colapsa



T1 T2

Figura 9 — **T1** (UE2020 capital → UE2020 interior): erros relativos grandes no NE, com a mesma marca. **T2** (UE2020 → antigas no mesmo município, $\geq 30+30$ seções): 165 municípios (155 em SP); erro médio $\approx -0,9\%$.

Leitura alinhada a Forsberg e à crítica metodológica: o padrão favorece a hipótese **geográfica**. R4 (erro = marca) não se sustenta neste desenho.

6. Forsberg Caps. 6 e 7 — indícios com significância estatística


Alinhamento a Ole J. Forsberg, *Understanding Elections through Statistics*, caps. 6–7. Premissa desta seção: **indício** $\neq$ **prova**. Associação estatística compatível com unfairness ou com efeito residual de urna **é indício**; prova exigiria destino discriminante e, no limite, registro independente.

6.1 Cap. 6 — Invalidação diferencial: há indício

Pergunta do capítulo: a taxa de brancos e nulos é independente do apoio ao candidato? Se não, há *unfairness* possível (fraude na contagem, ou demografia, alfabetização, cédula...). No protocolo deste projeto, esse achado **é indício** do que pode ser fraude — suficiente para o *Q.E.D.* intermediário —, embora **não** seja prova isolada.

Resultados nacionais (F3, ~92 mil locais, 2º turno):

Estatística	Valor	Significado
Quasi-binomial $pInv \sim pSup$ ($pSup$ = fração Lula)	coef. logit $\approx +0,35$; $z \gg 2$	Associação significativa: onde há mais Lula, há mais BN (em média nacional)
Mesmo modelo + fração urna antiga + interação	interação $\approx -0,13$ ($z \ll -2$)	O índice não é idêntico onde há mais urnas antigas
Moran I nos resíduos do modelo $pInv \sim pSup$ (+ old)	I $\approx 0,57$ ($z \approx 372$)	Os erros do Cap. 6 não são aleatórios no mapa : locais com invalidação acima (ou abaixo) do previsto tendem a ter vizinhos no mesmo sentido. I perto de 0 seria ausência de agrupamento; I $\approx 0,57$ é autocorrelação positiva forte




Invalidação

Figura 10 — Taxa de brancos+nulos por município. Ponto de partida do Cap. 6.

Onde o índice do Cap. 6 é maior

O coeficiente nacional esconde heterogeneidade. Reestimando por UF ($pInv \sim pSup + old$):



DI por UF

Figura 11 — Coeficiente do apoio a Lula sobre a invalidação, por UF. Azul: sentido “mais Lula → mais BN” (mesmo sinal do nacional). Vermelho: sentido oposto. Rotulados os z mais extremos.

UFs com índice **mais forte no sentido nacional** (coef. positivo e $|z|$ elevado): **SP, RS, MS, PB, ES, MG, PE, MT, RO, DF, BA, AC** (entre outras). UFs em que o coeficiente **inverte** (mais Lula → menos BN, também com $|z|$ alto): **CE, PA, PR, PI, AP, RN, MA, SE**. O índice existe nos dois casos — é a *dependência* entre invalidação e apoio que viola a independência do Cap. 6; o sinal diz *para que lado* a unfairness aparente aponta naquela UF.

Clusters LISA ($p < 0,05$) do tipo **HH** nos resíduos (invalidação **acima** do previsto pelo modelo nacional), por região:

Região	Locais HH significativos	Observação
Sudeste	7.619	Concentração grande em SP
Nordeste	7.430	BA, PE, PB, AL entre os maiores
Sul	617	Principalmente RS
Norte	278	Inclui AM
Centro-Oeste	81	Inclui MS

No total, cerca de **17%** dos locais caem em cluster HH significativo. CSV:

geografia/.../resultados/di_espacial_por_uf.csv e

di_espacial_lisa_HH_por_regiao.csv.

6.2 Cap. 7 — Geografia: o efeito urna residual também é indício


O Cap. 7 confirma que voto, invalidação e alocação de urnas são espacialmente autocorrelacionados (Moran da proporção de Lula $\approx 0,85$; da fração de urnas antigas $\approx 0,87$). Por isso um MQO sem estrutura espacial infla o “efeito urna”.

Especificação	Coef. fração urna antiga → % Lula	Leitura
MQO (locais, k=8)	+3,3 pp	Indício bruto, muito confundido com lugar
Defasagem espacial (GM_Lag)	+2,1 pp	Cai, permanece longe de zero
Erro espacial (GM_Error_Het)	+1,4 pp	Cai de novo; ainda ≠ neutro
Mesmo local + composição legislativa (referência)	+0,01 pp (t = 0,13)	Referência neutra <i>onde há comparação interna</i>

Sim: **+1,4 pp não é neutro**. Neutro, na escala que este projeto adotou no prédio, seria da ordem de **+0,01 pp**. O fato de os modelos espaciais globais **não** levarem o coeficiente a esse piso deixa de pé um **indício** — sinal estatístico ainda associado à fração de urnas antigas após controle espacial de coeficiente constante.


O que o Cap. 7 *ainda não* entrega, e por isso o indício **não** sobe sozinho a prova nem a indício discriminante “fraude”:

- 1. Calibração **F4a**: o mesmo modelo espacial, aplicado só onde a referência do prédio é ≈ 0 , precisa reproduzir ≈ 0 ; se não reproduzir, o +1,4 pp no resto do mapa pode ser viés do modelo, não fraude.
- 2. Efeitos que variam no mapa (SEM, GWR, SLEM).
- 3. Domínio sem comparação interna (~44% dos votos) ainda em aberto.



Moran

Figura 12 — Moran global: por que o Cap. 7 é obrigatório.




DI espacial

Figura 13 — Cap. 6 sob especificações espaciais: a associação invalidação × apoio permanece significativa ($z > 5$).

6.3 Síntese Caps. 6 e 7

Achado	É indício?	É prova?
Associação nacional BN × apoio a Lula (Cap. 6)	Sim	Não
Heterogeneidade por UF / clusters HH de resíduos	Sim (localiza o indício)	Não
Moran I $\approx 0,57$ nos resíduos do Cap. 6	Sim (o padrão é espacial)	Não — é diagnóstico de dependência
Coef. urna +1,4 pp após erro espacial (Cap. 7)	Sim (não é o neutro +0,01)	Não — falta F4a / efeitos variáveis
Azul no mapa de Lula	Não (é voto)	Não
Contraste urna no mesmo prédio ≈ 0	Atribui o indício <i>agregado de marca</i> sobretudo à alocação	—

6.4 Alcance além do prédio



Proximidade

Figura 14 — Fração do domínio só-urnas-antigas com UE2020 a $\leq r$ km noutro município.

6.5 Próximas etapas

1. **F4a** — Calibrar o modelo espacial na referência do prédio.
2. **F4b** — GWR e SLEM.
3. **F4c** — Pares cross-border.
4. **F4d** — Poder com fraudes sintéticas no domínio sem comparação interna.
5. Controles demográficos sobre o indício do Cap. 6 nas UFs de maior $|z|$.

7. Indícios examinados e destino

Indício	Distorção	Destino	Fundamento resumido
I1 Agregado entre modelos	$R \approx 1,17$ por estado	Alocação	$R \approx 1,05$ no município; UE2020 nas capitais
I2 Dentro da zona	+1,27 pp	Alocação	Concentrado em SP; nulo no local
I3 Resíduo paulista entre prédios	+0,26 pp	Alocação	Nulo dentro do prédio
I4 Erro da calibragem por UF	20–30%+ no N/NE	Alocação	Placebo T1 UE2020 capital → interior
I5 27 urnas AM sem Bolsonaro	Real	Alocação / alinhamento	Municípios só antigas; coerência com outros cargos
I6 PL alto / Bolsonaro baixo	Real	Alinhamento local	PL Senado fraco nas mesmas seções
I7 Mais BN nas antigas (zona)	+0,28 pp	Alocação (no local ≈ 0)	No local: $-0,07$ pp
I8 R intramunicipal RR	$R = 1,77$	A examinar	Falta teste por local
I9 Cap. 6 — BN × apoio a Lula	coef. $\approx +0,35$; $z \gg 2$; LISA HH $\sim 17\%$	Indício (unfairness possível)	Não é prova; forte em SP, RS, MS, PB, PE...
I10 Cap. 7 — coef. urna após erro espacial	+1,4 pp vs neutro +0,01	Indício (não neutro)	Não discriminante até F4a

8. Resposta à pergunta do leitor

“Há indício de fraude ou não?”

Há indícios — no sentido deste relatório: distorções estatisticamente significativas compatíveis com unfairness (Cap. 6) e com efeito residual associado à fração de urnas antigas após controle espacial global (Cap. 7, $+1,4 \text{ pp} \neq +0,01$). Isso é o que queríamos poder afirmar quando o teste rejeita a independência ou a neutralidade.

Não há prova de fraude por modelo de urna. O contraste no mesmo prédio atribui o indício *agregado de marca* sobretudo à alocação; os indícios I9 e I10 permanecem com destino a aprofundar (demografia, F4a–F4d), sem serem apagados por essa atribuição.

9. Artefatos e reprodução

Pasta / arquivo	Conteúdo
2026/analise/relatorio_calibragem.md	Calibragem de scores (corrigenda)
2026/analise/relatorio_base_e_controles.md	Base larga + T1/T2/T3
2026/geografia/claude_opus55_externo/docs/	Docs 01–07 (CMH, protocolo, scores, limites, geo)
2026/envio_calibragem_scores_johnrobson_2026-09-26.zip	Pacote enviado para atualização do site
2026/scripts/gerar_figuras_relatorio.py	Figuras deste relatório
2026/geografia/.../scripts/06_espacial.py, 07_di_espacial.py	Pipeline espacial

Reprodução geográfica (resumo):

```
cd 2026/geografia/claude_opus55_externo/scripts
python3 00_baixar_dados.py
python3 06_espacial.py
python3 07_di_espacial.py
```

10. Limitações

1. O teste de mesmo local não cobre municípios só com um modelo (~44% dos votos).
 2. Coordenadas têm erro residual (mediana baixa; excluir `conf_dist_km > 1` km em sensibilidade).
 3. GWR não tem teste nativo; SLEM depende da forma funcional.
 4. M5 é estruturalmente indeterminado com os registros públicos de 2022.
 5. Taxas calibradas não somam 1 em Bolsonaro+Lula (há “Outros”); o site, se atualizar scores, precisa decidir a renormação.
-

Relatório gerado no projeto PROJETO_ELEICOES_JOHNROBSON/2026. Figuras em [relatorio/figuras/](#).